

Three green apples are arranged in a cluster. One apple is in the foreground, slightly to the right, and two are behind it, one to the left and one to the right. They are all bright green with some yellowing at the stems.

人工知能

IE229 – ARTIFICIAL INTELLIGENCE

第8回講義: ニューラルネットワーク (2)

Lecture 8: Neural Networks (2)

二宮 崇 (Takashi Ninomiya)

愛媛大学 (Ehime University)

ninomiya.takashi.mk@ehime-u.ac.jp

人工知能第8回の講義です。第8回はニューラルネットワークの続きです。

今回の講義内容

- **ニューラルネットワークの学習**

- 計算グラフ
- 誤差逆伝播法




2

今回はニューラルネットワークの学習について学びます。ニューラルネットワークの学習に必要な計算グラフとそれを用いた誤差逆伝播法について勉強します。

【復習】 標準的なNNの構造

- 順伝播型(フィードフォワード)NN: 情報が入力側から出力側に一方向に伝わるNN



標準的なニューラルネットワーク(NN)はこの図のような構成になっています。ニューラルネットワークの計算がネットワークの左から右に向かって順に計算されるため、順伝播型(フィードフォワード)ニューラルネットワークと呼ばれています。これは2層のNNです。層の数はいろんな流儀があって、このネットワークに対して、1層と数える場合もあれば、2層、3層と数える場合があります。一般的にはこのNNは2層と数えられています。全体は入力層、中間層、出力層から成っていて、入力層は単に入力が与えられるだけで特に何かするわけではありません。中間層に入力を伝えることだけ行います。出力層は最後の出力を決定する層になります。入力層と出力層の間にある層は中間層と呼ばれます。中間層を多層化することで深層化することになります。深層化したニューラルネットワークで学習することを深層学習(deep learning)と言います。

ここからは、

$$\frac{\partial L}{\partial w_i}$$

パラメータ(重み変数)の勾配の計算を効率良く
行う「**誤差逆伝播法(Back Propagation)**」
を学びます



ここからは、パラメータ(重み変数)の勾配の計算を効率良く行う「誤差逆伝播法(Back Propagation)」を学びます

連鎖律 (chain rule)

- 合成関数(複数の関数によって構成される関数)の微分に関するルール: 合成関数の微分は、構成するそれぞれの関数の微分の積で計算できる

例: $z = t^2$
 $t = x + 2y$

$z = (x + 2y)^2$ のこと

連鎖律

$\frac{\partial z}{\partial x} = \frac{\partial z}{\partial t} \frac{\partial t}{\partial x}$ と理解
打ち消し

$$\frac{\partial z}{\partial x} = \frac{\partial z}{\partial t} \frac{\partial t}{\partial x} = 2t \cdot 1 = 2(x + 2y)$$



$$\frac{\partial z}{\partial y} = \frac{\partial z}{\partial t} \frac{\partial t}{\partial y} = 2t \cdot 2 = 4(x + 2y)$$

5

誤差逆伝播法を理解するためには微分に関する連鎖律(chain rule)を理解する必要があります。連鎖律は、合成関数(複数の関数によって構成される関数)の微分に関するルールです。このルールは簡単に言うと、合成関数の微分は、構成するそれぞれの関数の微分の積で計算できる、という規則です。

例えば、 $z = (x + 2y)^2$ を $z = t^2$ と $t = x + 2y$ の合成関数とみなすと、次の様に分解して微分を計算することができます。

$$\begin{aligned} \frac{\partial z}{\partial x} &= \frac{\partial z}{\partial t} \frac{\partial t}{\partial x} = 2t \cdot 1 = 2(x + y) \\ \frac{\partial z}{\partial y} &= \frac{\partial z}{\partial t} \frac{\partial t}{\partial y} = 2t \cdot 2 = 4(x + y) \end{aligned}$$

これは、 ∂t で打ち消し合って、等式が成り立っていると考えれば良いです。この場合は、 $z = t^2$ となっていて、 t という1変数だけで構成される合成関数なので、比較的簡単な場合となります。

多変数の連鎖律

● 多変数から成る合成関数の微分に関するルール

$z = f(u, v, w)$ のとき

$$\frac{\partial z}{\partial x} = \frac{\partial z}{\partial u} \frac{\partial u}{\partial x} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial x} + \frac{\partial z}{\partial w} \frac{\partial w}{\partial x}$$

関数 f に対し u, v, w についてのみ偏微分すれば良い。

例：
 $z = uv$
 $u = x^2 + y^2$
 $v = \sin w$
 $w = xy$

u, v, w に対して再帰的に x について微分すれば良い。

$$\begin{aligned} \frac{\partial z}{\partial x} &= \frac{\partial z}{\partial u} \frac{\partial u}{\partial x} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial x} = v \frac{\partial u}{\partial x} + u \frac{\partial v}{\partial x} = v \cdot 2x + u \left(\frac{\partial v}{\partial w} \frac{\partial w}{\partial x} \right) \\ &= v \cdot 2x + u \cdot \cos w \cdot \frac{\partial w}{\partial x} = v \cdot 2x + u \cdot \cos w \cdot y \end{aligned}$$

6

ニューラルネットワークでは複数の変数で構成される一般的な合成関数となっています。従って、多変数の連鎖律を理解する必要があります。ここでは、 z が u, v, w の3変数から計算されるとします。つまり、 $z = f(u, v, w)$ とします。この場合の連鎖律は次のようになります。

$$\frac{\partial z}{\partial x} = \frac{\partial z}{\partial u} \frac{\partial u}{\partial x} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial x} + \frac{\partial z}{\partial w} \frac{\partial w}{\partial x}$$

構成される各変数で微分したものと各変数を微分したものをかけて、それらをすべて足合わせたものになっています。各項の左半分は局所的に関数 f に対し u, v, w について偏微分すれば良く、右半分については u, v, w に対して再帰的に x について微分すれば、同様に合成関数を構成する各関数の微分にすべて分解することができます。

例えば、 $z = uv$

$$\begin{aligned} u &= x^2 + y^2 \\ v &= \sin xy \end{aligned}$$

としたとき、


$$\frac{\partial z}{\partial x} = \frac{\partial z}{\partial u} \frac{\partial u}{\partial x} + \frac{\partial z}{\partial v} \frac{\partial v}{\partial x} = v \frac{\partial u}{\partial x} + u \frac{\partial v}{\partial x} = v \cdot 2x + u \cdot \cos xy \cdot y$$

となります。

なぜ連鎖律はNNの学習に関係する？

● 巨大で複雑な関数の自動微分を実現したいから

- NNは単純な関数を組み合わせた複雑な関数とみなせる
- 複雑な関数 $L(w)$ の偏微分 $\frac{\partial L}{\partial w}$ を計算したい
- 連鎖律で基本的な関数(四則演算や、三角関数、活性化関数など)の微分に分解できる
- 連鎖律で分解された微分を効率的に計算できる(誤差逆伝播法)



何故連鎖律はニューラルネットワーク(NN)の学習に関係するのでしょうか？

今まで勉強したように、NNの学習には損失を重み変数(パラメータ)で微分した勾配 $\frac{\partial L}{\partial w}$ の計算が必要でした。NNは掛け算、足し算、活性化関数等の数式の組み合わせで出力とデータ全体の損失の計算を行っています。つまり、出力も損失も一つの巨大で複雑な関数になっていて、特にNNの学習には、損失を重み変数で微分した勾配が必要になるので、この巨大な関数の微分を行う必要があります。

しかし、この巨大な関数の導関数を前もって紙の上で計算するのはかなり大変です。また、新しいモデルを作るごとにまた紙の上で計算するのは大変面倒です。そこで、自動的に微分を行うことを考えます。連鎖律を用いると巨大な関数の微分も、それを構成する個々の関数の微分に分解できるので、基本的な関数(四則演算や、三角関数、活性化関数など)の導関数だけ与えて、連鎖律を用いて計算すれば基本的な関数の組み合わせによる巨大で複雑な関数の微分を自動的に計算することができます。もし、基本的な関数が不足していれば、その基本的な関数の導関数だけ新しく追加してやれば良いことになります。

また、連鎖率を用いるもう一つの理由として、計算効率の問題があります。単純に連鎖率を用いて、損失関数の微分を計算すると同じ微分の計算が何度もでてくることになり、効率が大変悪く、現実的な時間で学習を行うことができません。そこで、同じ計算を二度繰り返さないように微分を計算する方法が誤差逆伝播法となります。誤差逆伝播法では計算グラフというグラフを用いて、連鎖律で分解された微分を効率的に計算することができます。

連鎖律を用いた微分

- 例: 変数 x_1, x_2, x_3 から y を計算

$$s_1 = x_1 x_2 \quad t_1 = s_1 s_2$$

$$s_2 = x_1 x_3 \quad t_2 = s_1 s_3 \quad y = t_1^2 + t_2^2 + t_3^2$$

$$s_3 = x_2 x_3 \quad t_3 = s_2 s_3$$

局所的に微分可能

つまり、

$$y = (x_1^2 x_2 x_3)^2 + (x_1 x_2^2 x_3)^2 + (x_1 x_2 x_3^2)^2$$

$$\frac{\partial y}{\partial x_1} = \frac{\partial y}{\partial t_1} \frac{\partial t_1}{\partial x_1} + \frac{\partial y}{\partial t_2} \frac{\partial t_2}{\partial x_1} + \frac{\partial y}{\partial t_3} \frac{\partial t_3}{\partial x_1}$$

$$= 2t_1 \frac{\partial t_1}{\partial x_1} + 2t_2 \frac{\partial t_2}{\partial x_1} + 2t_3 \frac{\partial t_3}{\partial x_1}$$

再帰的微分

$$= 2t_1 \left(\frac{\partial t_1}{\partial s_1} \frac{\partial s_1}{\partial x_1} + \frac{\partial t_1}{\partial s_2} \frac{\partial s_2}{\partial x_1} \right) + 2t_2 \left(\frac{\partial t_2}{\partial s_1} \frac{\partial s_1}{\partial x_1} + \frac{\partial t_2}{\partial s_3} \frac{\partial s_3}{\partial x_1} \right) + 2t_3 \left(\frac{\partial t_3}{\partial s_2} \frac{\partial s_2}{\partial x_1} + \frac{\partial t_3}{\partial s_3} \frac{\partial s_3}{\partial x_1} \right)$$

$$= 2t_1 \left(s_2 \frac{\partial s_1}{\partial x_1} + s_1 \frac{\partial s_2}{\partial x_1} \right) + 2t_2 \left(s_3 \frac{\partial s_1}{\partial x_1} + s_1 \frac{\partial s_3}{\partial x_1} \right) + 2t_3 \left(s_3 \frac{\partial s_2}{\partial x_1} + s_2 \frac{\partial s_3}{\partial x_1} \right)$$

$$= 2t_1 (s_2 x_2 + s_1 x_3) + 2t_2 (s_3 x_2 + s_1 x_3) + 2t_3 (s_3 x_3)$$

$$= 2x_1^2 x_2 x_3 (2x_1 x_2 x_3) + 2x_1 x_2^2 x_3 (x_2^2 x_3) + 2x_1 x_2 x_3^2 (x_2 x_3^2)$$

しかし、 $\frac{\partial s_1}{\partial x_1}$ と $\frac{\partial s_2}{\partial x_1}$ と $\frac{\partial s_3}{\partial x_1}$ は同じ計算を2回繰り返している

8

連鎖律を使った例をみましょう。変数 x_1, x_2, x_3 から y を計算します。

$$s_1 = x_1 x_2 \quad t_1 = s_1 s_2$$

$$s_2 = x_1 x_3 \quad t_2 = s_1 s_3 \quad y = t_1^2 + t_2^2 + t_3^2$$

$$s_3 = x_2 x_3 \quad t_3 = s_2 s_3$$

より複雑で、NNの計算に近い計算式になっています。ここでは、 $\frac{\partial y}{\partial x_1}$ の計算を考えてみます。連鎖律を使って、

$$\frac{\partial y}{\partial x_1} = \frac{\partial y}{\partial t_1} \frac{\partial t_1}{\partial x_1} + \frac{\partial y}{\partial t_2} \frac{\partial t_2}{\partial x_1} + \frac{\partial y}{\partial t_3} \frac{\partial t_3}{\partial x_1}$$

となります。各項の左半分はそれぞれ局所的に微分可能なので、まず、それらを計算して、

$$= 2t_1 \frac{\partial t_1}{\partial x_1} + 2t_2 \frac{\partial t_2}{\partial x_1} + 2t_3 \frac{\partial t_3}{\partial x_1}$$

となります。各項の右半分は再帰的に微分を繰り返して行います。連鎖律を同様に用いると、

$$= 2t_1 \left(\frac{\partial t_1}{\partial s_1} \frac{\partial s_1}{\partial x_1} + \frac{\partial t_1}{\partial s_2} \frac{\partial s_2}{\partial x_1} \right) + 2t_2 \left(\frac{\partial t_2}{\partial s_1} \frac{\partial s_1}{\partial x_1} + \frac{\partial t_2}{\partial s_3} \frac{\partial s_3}{\partial x_1} \right) + 2t_3 \left(\frac{\partial t_3}{\partial s_2} \frac{\partial s_2}{\partial x_1} + \frac{\partial t_3}{\partial s_3} \frac{\partial s_3}{\partial x_1} \right)$$

後は、それぞれの偏微分を計算すれば $\frac{\partial y}{\partial x_1}$ が求まります。

$$\frac{\partial y}{\partial x_1} = 2x_1^2 x_2 x_3 (2x_1 x_2 x_3) + 2x_1 x_2^2 x_3 (x_2^2 x_3) + 2x_1 x_2 x_3^2 (x_2 x_3^2)$$

しかし、 $\frac{\partial s_1}{\partial x_1}$ と $\frac{\partial s_2}{\partial x_1}$ と $\frac{\partial s_3}{\partial x_1}$ は同じ計算を2回繰り返してしまっています。

連鎖律を用いた微分

- 例2: 変数 x_1, x_2, x_3 から y を計算

$$\begin{aligned} \frac{\partial y}{\partial x_1} &= \frac{\partial y}{\partial t_1} \frac{\partial t_1}{\partial x_1} + \frac{\partial y}{\partial t_2} \frac{\partial t_2}{\partial x_1} + \frac{\partial y}{\partial t_3} \frac{\partial t_3}{\partial x_1} \\ &= \frac{\partial y}{\partial t_1} \left(\frac{\partial t_1}{\partial s_1} \frac{\partial s_1}{\partial x_1} + \frac{\partial t_1}{\partial s_2} \frac{\partial s_2}{\partial x_1} \right) + \frac{\partial y}{\partial t_2} \left(\frac{\partial t_2}{\partial s_1} \frac{\partial s_1}{\partial x_1} + \frac{\partial t_2}{\partial s_3} \frac{\partial s_3}{\partial x_1} \right) + \frac{\partial y}{\partial t_3} \left(\frac{\partial t_3}{\partial s_2} \frac{\partial s_2}{\partial x_1} + \frac{\partial t_3}{\partial s_3} \frac{\partial s_3}{\partial x_1} \right) \end{aligned}$$

$$\begin{aligned} s_1 &= x_1 x_2 & t_1 &= s_1 s_2 \\ s_2 &= x_1 x_3 & t_2 &= s_1 s_3 \\ s_3 &= x_2 x_3 & t_3 &= s_2 s_3 \\ y &= t_1^2 + t_2^2 + t_3^2 \end{aligned}$$

このように局所的な微分の計算と再帰的計算を繰り返す。


同じ計算を繰り返しており、そのため指数爆発的な計算量の計算になってしまう。

9

たかが2回と思うかもしれませんが、再帰的に微分を行っているため、もっと複雑で深い式を扱っていると、同じ微分の計算を指数爆発的に行うことになってしまいます。このスライドだと、黄色の部分はそれぞれまったく同じ計算になりますし、黄緑色、ピンク色の部分もそれぞれ同じ計算になっています。

連鎖律を用いた微分

- 例2: 変数 x_1, x_2, x_3 から y を計算



$$\begin{aligned} s_1 &= x_1 x_2 & t_1 &= s_1 s_2 \\ s_2 &= x_1 x_3 & t_2 &= s_1 s_3 \\ s_3 &= x_2 x_3 & t_3 &= s_2 s_3 \\ y &= t_1^2 + t_2^2 + t_3^2 \end{aligned}$$

同じ微分を繰り返さないように計算結果を使い回すことで効率化が可能(誤差逆伝播法)

10

ここで、同じ計算を一つにまとめて、同じ微分を繰り返さないように計算結果を使い回すことで効率化することができます。グラフを使ってこれらの計算結果を使い回し効率化を実現するアルゴリズムが誤差逆伝播法(back propagation)と呼ばれる手法になります。

誤差逆伝播法 (Back Propagation)

- **損失に対する各パラメータの微分を計算する方法**

- 次の計算ステップで全てのパラメータの微分を計算
 1. 計算グラフを作る
 2. 入力から出力に向かって順方向に計算(順伝播)
 3. 出力から入力に向かって逆方向に微分を計算(逆伝播)
- 同じ微分の計算を繰り返さない(動的計画法の一種)



11

誤差逆伝播法(back propagation)は、同じ微分の計算を繰り返さない動的計画法の一種です。次の計算ステップで全てのパラメータの微分を自動的に計算します。

1. 計算グラフを作る
2. 入力から出力に向かって順方向に計算(順伝播)
3. 出力から入力に向かって逆方向に微分を計算(逆伝播)


計算グラフによる解釈

- 計算グラフ: 計算の過程をグラフ(ノードとエッジ)で表したもの

$s = f(x_1, x_2), t = g(s, x_3), y = h(t, x_4)$ の計算グラフ

○ : 変数

□ : 関数 (演算の中身)



12

まず、計算グラフの作り方からです。計算グラフは計算の過程をグラフ(ノードとエッジ)で表したものです。変数は○のノードで表されて、関数は四角のノードで表します。関数に inputs する変数と関数が出力する変数をエッジで結びます。エッジは入力から出力の方向に向う矢印にします。

スライドのグラフは、 $s = f(x_1, x_2), t = g(s, x_3), y = h(t, x_4)$ の計算を計算グラフにしたものです。まず、 x_1, x_2 が f に入力されて、出力の s を得ます。続いて、その出力 s と x_3 を g に入力して出力 t を得ます。最後にその出力 t と x_4 を関数 h に入力して出力 y を得ます。このようにグラフの流れにそって計算すると全体の式の計算ができるようになっています。計算の流れを可視化したものとも考えられます。


計算グラフによる解釈

- 計算グラフ: 計算の過程をグラフ(ノードとエッジ)で表したもの

$s = f(x_1, x_2), t = g(s, x_3), y = h(t, x_4)$ の計算グラフ

○ : 変数

□ : 関数 (演算の中身)



各関数は

- ・ 入力を受け取ったときの出力の計算
 - ・ 入力となる各変数に対する偏微分の計算
- ができれば良い

13

誤差逆伝播法では、各関数は、

- ・ 入力を受け取ったときの出力の計算

に加えて、

- ・ 入力となる各変数に対する偏微分の計算ができる

ようにしておきます。


つまり、この場合、関数 f は f の計算だけでなく、 $\frac{\partial s}{\partial x_1}, \frac{\partial s}{\partial x_2}$ の計算ができ、関数 g は g の計算だけでなく $\frac{\partial t}{\partial s}, \frac{\partial t}{\partial x_3}$ の計算もできるようにしておき、関数 h は h の計算だけでなく、 $\frac{\partial y}{\partial t}, \frac{\partial y}{\partial x_4}$ の計算もできるようにしておきます。それぞれの関数の導関数を用意しておくことでこれらの値が計算できるようになります。例えば、 $\frac{\partial s}{\partial x_1} = \frac{\partial f}{\partial x_1}(x_1, x_2)$ によって計算できます。

計算グラフによる解釈

● 順伝播の計算

$s = f(x_1, x_2), t = g(s, x_3), y = h(t, x_4)$ の計算グラフ

○ : 変数
□ : 関数 (演算の中身)



全体の入力(x_1, x_2, x_3, x_4)を与えて、すべてのノードの値(s, t, y)を計算する。

14


誤差逆伝播法の最初のステップは、順方向の計算(順伝播)です。
全体の入力(x_1, x_2, x_3, x_4)を与えて、すべてのノードの値(s, t, y)をグラフの流れに沿って全て計算します。

計算グラフによる解釈

● 逆伝播の計算

$s = f(x_1, x_2), t = g(s, x_3), y = h(t, x_4)$ の計算グラフ

○ : 変数
□ : 関数 (演算の中身)



次に逆伝播の計算です。出力から開始します。出力(上流)から入力(下流)に向かって計算します。


上流のノードから伝達された値に局所的な微分を乗算して下流のノードに渡していきます。最初は y から t へ渡す計算と y から x_4 にわたす計算を行います。関数 h は $\frac{\partial y}{\partial t}$ を計算する導関数を持っているので、順伝播で計算された t と x_4 の値を使って、 $\frac{\partial y}{\partial t} = \frac{\partial h}{\partial t}(t, x_4)$ を計算します。 h の導関数 $\frac{\partial h}{\partial t}$ は t, x_4 を引数とする関数となることに注意してください。順伝播で t と x_4 には具体的な実数が入っているため、 $\frac{\partial y}{\partial t}$ も具体的な実数となります。 $\frac{\partial y}{\partial t}$ の値はグラフの下流に渡していきます。同様にして、 $\frac{\partial y}{\partial x_4}$ の値も計算します。 $\frac{\partial y}{\partial x_4}$ はここで終点となって、このノードに渡された値が求めるべき $\frac{\partial y}{\partial x_4}$ の値となります。

計算グラフによる解釈

● 逆伝播の計算

$s = f(x_1, x_2), t = g(s, x_3), y = h(t, x_4)$ の計算グラフ

○ : 変数
□ : 関数 (演算の中身)



今度は t から s と x_3 へ値を渡す計算を行います。

t の上流から $\frac{\partial y}{\partial t}$ の値が流れてきています。ここで、 g には $\frac{\partial t}{\partial s}$ を計算する機能をつけているので、それを使って $\frac{\partial t}{\partial s}$ を計算し、上流から流れてきた $\frac{\partial y}{\partial t}$ の値と掛け合わせて $\frac{\partial y}{\partial t} \frac{\partial t}{\partial s}$ を計算し下流に流していきます。


x_3 はここで終点となりますが、上流から流れてきた $\frac{\partial y}{\partial t}$ に $\frac{\partial t}{\partial x_3}$ をかけ合わせた $\frac{\partial y}{\partial t} \frac{\partial t}{\partial x_3}$ を計算します。この値が $\frac{\partial y}{\partial x_3}$ となります。

計算グラフによる解釈

● 逆伝播の計算

$s = f(x_1, x_2), t = g(s, x_3), y = h(t, x_4)$ の計算グラフ

○ : 変数
□ : 関数 (演算の中身)



最後に s から x_1 と x_2 に向かう流れの計算を行って、 $\frac{\partial y}{\partial x_1}$ と $\frac{\partial y}{\partial x_2}$ を求めます。

上流から $\frac{\partial y}{\partial t} \frac{\partial t}{\partial s}$ の値が流れてきているので、まず、 $\frac{\partial s}{\partial x_1}$ を計算し、 $\frac{\partial y}{\partial t} \frac{\partial t}{\partial s}$ と掛け合わせることで $\frac{\partial y}{\partial t} \frac{\partial t}{\partial s} \frac{\partial s}{\partial x_1}$ を求めます。これが $\frac{\partial y}{\partial x_1}$ となります。

同様に、 $\frac{\partial s}{\partial x_2}$ を計算し、 $\frac{\partial y}{\partial t} \frac{\partial t}{\partial s}$ と掛け合わせることで $\frac{\partial y}{\partial t} \frac{\partial t}{\partial s} \frac{\partial s}{\partial x_2}$ を求めます。これが $\frac{\partial y}{\partial x_2}$ となります。

よって、 y の勾配 $(\frac{\partial y}{\partial x_1}, \frac{\partial y}{\partial x_2}, \frac{\partial y}{\partial x_3}, \frac{\partial y}{\partial x_4})$ の計算できたということになります。

連鎖律を用いた微分 2


- 一般の数式 (順伝播で再合流する場合)

- x_1, x_2 から y を計算する過程

$$\begin{aligned} z_1 &= f_1(x_1) \\ z_2 &= f_2(x_1, x_2) \\ y &= g(z_1, z_2) \end{aligned}$$

$$\frac{\partial y}{\partial x_1} = \frac{\partial y}{\partial z_1} \frac{\partial z_1}{\partial x_1} + \frac{\partial y}{\partial z_2} \frac{\partial z_2}{\partial x_1}$$

$$\frac{\partial y}{\partial x_2} = \frac{\partial y}{\partial z_1} \frac{\partial z_1}{\partial x_2} + \frac{\partial y}{\partial z_2} \frac{\partial z_2}{\partial x_2} = \frac{\partial y}{\partial z_2} \frac{\partial z_2}{\partial x_2}$$



18

次に一般的な形の計算グラフについて誤差逆伝播法を適用することを考えます。具体的には、順伝播で一度計算結果が分かれて用いられて再び合流する場合です。

例として、

$$\begin{aligned} z_1 &= f_1(x_1) \\ z_2 &= f_2(x_1, x_2) \\ y &= g(z_1, z_2) \end{aligned}$$

を考えてみます。これに対して連鎖律を適用すると、 $\frac{\partial y}{\partial x_1}$ は、

$$\frac{\partial y}{\partial x_1} = \frac{\partial y}{\partial z_1} \frac{\partial z_1}{\partial x_1} + \frac{\partial y}{\partial z_2} \frac{\partial z_2}{\partial x_1}$$

となりますが、 $\frac{\partial z_1}{\partial x_1}$ も $\frac{\partial z_2}{\partial x_1}$ もどちらも x_1 の影響を受けるため、微分しても0になりません。

従って、この場合は、和の形で計算する必要があります。


$\frac{\partial y}{\partial x_2}$ は、 $\frac{\partial y}{\partial x_2} = \frac{\partial y}{\partial z_1} \frac{\partial z_1}{\partial x_2} + \frac{\partial y}{\partial z_2} \frac{\partial z_2}{\partial x_2}$ となりますが、 $\frac{\partial y}{\partial z_1} \frac{\partial z_1}{\partial x_2} = 0$ となるため、 $\frac{\partial y}{\partial x_2} = \frac{\partial y}{\partial z_2} \frac{\partial z_2}{\partial x_2}$ となって、先程の例と計算は同様にできます。

$$\frac{\partial y}{\partial x_2} = \frac{\partial y}{\partial z_2} \frac{\partial z_2}{\partial x_2}$$

計算グラフによる解釈 2

$$z_1 = f_1(x_1), z_2 = f_2(x_1, x_2), y = g(z_1, z_2)$$

$$\frac{\partial y}{\partial x_1} = \frac{\partial y}{\partial z_1} \frac{\partial z_1}{\partial x_1} + \frac{\partial y}{\partial z_2} \frac{\partial z_2}{\partial x_1}, \quad \frac{\partial y}{\partial x_2} = \frac{\partial y}{\partial z_2} \frac{\partial z_2}{\partial x_2}$$



19


具体的な計算の流れをみていきましょう。

まず、出力の y から始めます。 y から z_1 に至る流れでは、 $\frac{\partial y}{\partial z_1}$ を計算して、この結果を z_1 に渡します。同様に y から z_2 に至る流れでは、 $\frac{\partial y}{\partial z_2}$ を計算して、この結果を z_2 に渡します。

計算グラフによる解釈 2

$$z_1 = f_1(x_1), z_2 = f_2(x_1, x_2), y = g(z_1, z_2)$$

$$\frac{\partial y}{\partial x_1} = \frac{\partial y}{\partial z_1} \frac{\partial z_1}{\partial x_1} + \frac{\partial y}{\partial z_2} \frac{\partial z_2}{\partial x_1}, \quad \frac{\partial y}{\partial x_2} = \frac{\partial y}{\partial z_2} \frac{\partial z_2}{\partial x_2}$$



20


続いて、 z_2 から x_2 に至る流れをみてみます。上流から $\frac{\partial y}{\partial z_2}$ の値が流れてきているので、 $\frac{\partial z_2}{\partial x_2}$ の値を計算して、かけ合わせることで、 $\frac{\partial y}{\partial z_2} \frac{\partial z_2}{\partial x_2}$ を求めます。この値が $\frac{\partial y}{\partial x_2}$ となります。

計算グラフによる解釈 2

$$z_1 = f_1(x_1), z_2 = f_2(x_1, x_2), y = g(z_1, z_2)$$

$$\frac{\partial y}{\partial x_1} = \frac{\partial y}{\partial z_1} \frac{\partial z_1}{\partial x_1} + \frac{\partial y}{\partial z_2} \frac{\partial z_2}{\partial x_1}, \quad \frac{\partial y}{\partial x_2} = \frac{\partial y}{\partial z_2} \frac{\partial z_2}{\partial x_2}$$

合流地点では各パスから伝播してきた勾配を足し合わせる



21

最後に z_1 と z_2 から x_1 に合流する流れの計算を行います。

まず、 z_1 から x_1 に至る流れをみてみます。上流から $\frac{\partial y}{\partial z_1}$ の値が流れてきているので、この値に $\frac{\partial z_1}{\partial x_1}$ をかけることで、 $\frac{\partial y}{\partial z_1} \frac{\partial z_1}{\partial x_1}$ が求まります。この値を x_1 に流します。

続いて、 z_2 から x_1 に至る流れをみてみます。こちらは上流から $\frac{\partial y}{\partial z_2}$ の値が流れてきているので、この値に $\frac{\partial z_2}{\partial x_1}$ をかけることで、 $\frac{\partial y}{\partial z_2} \frac{\partial z_2}{\partial x_1}$ が求まります。この値を x_1 に流します。

最後に、 z_1 から x_1 に流れてきた $\frac{\partial y}{\partial z_1} \frac{\partial z_1}{\partial x_1}$ と、 z_2 から x_1 に流れてきた $\frac{\partial y}{\partial z_2} \frac{\partial z_2}{\partial x_1}$ を足し合わせると、 $\frac{\partial y}{\partial z_1} \frac{\partial z_1}{\partial x_1} + \frac{\partial y}{\partial z_2} \frac{\partial z_2}{\partial x_1}$ となって、この値が $\frac{\partial y}{\partial x_1}$ となります。

つまり、合流地点では各パスから伝播してきた勾配を足し合わせれば良い、ということになります。この操作によって一般的な計算式に対する微分を計算できるようになります。


計算グラフ上で偏微分の計算ができる理由

● 損失 L とあるパラメータ w の偏微分 $\frac{\partial L}{\partial w}$ の計算

- w 以外の全てのパラメータを定数と考える
- w から直接計算される計算結果を $a_1, \dots, a_m$ とする
- 損失 L は、 $a_1, \dots, a_m$ から計算される巨大な関数 $L(a_1, \dots, a_m)$ とみなせる

$$\frac{\partial L}{\partial w} = \frac{\partial L}{\partial a_1} \frac{\partial a_1}{\partial w} + \dots + \frac{\partial L}{\partial a_m} \frac{\partial a_m}{\partial w}$$

各 a_i に対し、 $\frac{\partial L}{\partial a_i}$ を計算グラフ上で再帰的に計算(つまり、逆伝播で計算)



22

誤差逆伝播法で何故偏微分の計算ができているのでしょうか？ここで、損失 L とあるパラメータ w の偏微分 $\frac{\partial L}{\partial w}$ の計算について考えてみます。多変数の連鎖律の説明に従うと、損失に近い、つまりネットワークの一番右側から、 $\frac{\partial L}{\partial w} = \frac{\partial L}{\partial z_1} \frac{\partial z_1}{\partial w} + \dots + \frac{\partial L}{\partial z_n} \frac{\partial z_n}{\partial w}$ の計算を再帰的に行うことで、偏微分の計算ができるということでした。しかし、先程の誤差逆伝播法の説明では、損失に近いネットワークの右側で足し算を行うのではなく、パラメータに近いネットワークの左側で足し算を行っていました。どうしてこの計算で偏微分の計算ができているのでしょうか。

まず、ここでは、大前提として、損失 L とあるパラメータ w の偏微分だけについて考えます。つまり、 w 以外の全てのパラメータを定数と考えます。続いて、 w から直接計算される結果を $a_1, \dots, a_m$ とします。すると、スライドの図で表せられるように、損失 L は、 $a_1, \dots, a_m$ から計算される巨大な関数 $L(a_1, \dots, a_m)$ とみなすことができます。ここで、連鎖律を適用すると、

$$\frac{\partial L}{\partial w} = \frac{\partial L}{\partial a_1} \frac{\partial a_1}{\partial w} + \dots + \frac{\partial L}{\partial a_m} \frac{\partial a_m}{\partial w}$$

となります。あとは、これを再帰的に適用していきます。各 a_i に対し、 $\frac{\partial L}{\partial a_i}$ を計算グラフ上で再帰的に計算していきます。つまり、ネットワークの右から左に向かって計算し、合流するところで足し算を行えば良い、ということがわかります。

計算グラフ上で偏微分の計算ができる理由


● 損失 L とあるパラメータ w の偏微分 $\frac{\partial L}{\partial w}$ の計算

計算グラフ上の変数にだけ注目して、 L と w をつなぐ全てのパス集合を P と
おくと、

$$\frac{\partial L}{\partial w} = \frac{\partial L}{\partial z_1} \frac{\partial z_1}{\partial w} + \dots + \frac{\partial L}{\partial z_n} \frac{\partial z_n}{\partial w} = \sum_{p \in P} \prod_{(u,v) \in p} \frac{\partial v}{\partial u}$$

全体の微分は各パスの微分の和となり、各パスの微分は局所的な微分の積
となっている。従って、右から左に計算しても左から右に計算しても同じ。

$$\sum_{p \in P} \prod_{(u,v) \in p} \frac{\partial v}{\partial u} = \frac{\partial L}{\partial a_1} \frac{\partial a_1}{\partial w} + \dots + \frac{\partial L}{\partial a_m} \frac{\partial a_m}{\partial w}$$



23

また、別の解釈の方法として、次のように考えることもできます。同様に、損失 L とある
パラメータ w の偏微分 $\frac{\partial L}{\partial w}$ の計算についてだけ考えます。計算グラフ上の変数にだけ注
目して、 L と w をつなぐ全てのパス集合を P とおくと、

$$\frac{\partial L}{\partial w} = \frac{\partial L}{\partial z_1} \frac{\partial z_1}{\partial w} + \dots + \frac{\partial L}{\partial z_n} \frac{\partial z_n}{\partial w} = \sum_{p \in P} \prod_{(u,v) \in p} \frac{\partial v}{\partial u}$$

となり、全体の微分は各パスの微分の和となり、各パスの微分は局所的な微分の積と
なります。従って、右から左に計算しても左から右に計算しても同じになるので、先程の
計算どおり、

$$\sum_{p \in P} \prod_{(u,v) \in p} \frac{\partial v}{\partial u} = \frac{\partial L}{\partial a_1} \frac{\partial a_1}{\partial w} + \dots + \frac{\partial L}{\partial a_m} \frac{\partial a_m}{\partial w}$$

となるということです。

そして、左から右に向かって各パラメータの偏微分を計算する場合は、パラメータごと
に途中の計算結果が異なるため、非常に計算効率が悪いこととなります(パラメータ
数×ネットワークサイズの計算が必要)、右から左に向かって計算すると、最後のパラ
メータの計算以外は全て共有されることになるので、順伝播と同じ計算量(ネットワーク
サイズ)で計算できることがわかります。

誤差逆伝播法の例


入力 x 、変数 w_1, w_2 から次のように出力値 y を計算する過程を考える

$$s = x \times w_1$$

$$t = s^2$$

$$y = t + w_2$$

入力 $x = 2$ 、変数 $w_1 = 3$ $w_2 = 4$ における変数 w_1, w_2 の勾配 $\nabla y = \left(\frac{\partial y}{\partial w_1}, \frac{\partial y}{\partial w_2} \right)$ を求める



24

誤差逆伝播法の例をみてみましょう。入力 x 、変数 w_1, w_2 から出力値 y を計算する計算グラフを用いて、各変数(w_1, w_2)に対する出力の勾配を求めます。ここでは、入力 $x = 2$ 、変数 $w_1 = 3$ $w_2 = 4$ における変数 w_1, w_2 の勾配 $\nabla y = \left(\frac{\partial y}{\partial w_1}, \frac{\partial y}{\partial w_2} \right)$ を求めることにします。

計算式は、 $s = x \times w_1$ 、 $t = s^2$ 、 $y = t + w_2$ とします。すると、計算グラフはスライドの図のようになります。勾配法を適用するときは、具合的な重み変数(パラメータ)の値を用いて、現在の誤差関数に対する重み変数の勾配を計算しています。従って、入力 x 、重み変数 w_1, w_2 には具体的な数値が入っていることを想定して良い、ということになります。

誤差逆伝播法の例

入力 x 、変数 w_1, w_2 から次のように出力値 y を計算する過程を考える

$$s = x \times w_1$$


$$t = s^2$$

$$y = t + w_2$$

入力 $x = 2$ 、重み変数 $w_1 = 3, w_2 = 4$ における重み変数 w_1, w_2 の勾配

$\nabla y = \left(\frac{\partial y}{\partial w_1}, \frac{\partial y}{\partial w_2} \right)$ を求める

順伝播の計算



25

まず、順伝播の計算を行います。 x と w_1 を入力して、 $x \times w_1$ を計算して s を求めます。続いて、 s の二乗を計算して t を求めます。最後に t と w_2 を足し合わせることで y を求めます。この手続きによって、 s, t, y の全ての値が求まります。

誤差逆伝播法の例


入力 x 、変数 w_1, w_2 から次のように出力値 y を計算する過程を考える

$$s = x \times w_1, \quad t = s^2, \quad y = t + w_2$$

入力 $x = 2$ 、重み変数 $w_1 = 3, w_2 = 4$ における重み変数 w_1, w_2 の勾配

$\nabla y = \left(\frac{\partial y}{\partial w_1}, \frac{\partial y}{\partial w_2} \right)$ を求める

逆伝播の計算



26

続いて、逆伝播の計算を行います。最初は1の値を y に渡します。 $\frac{\partial y}{\partial t} = 1$ 、 $\frac{\partial y}{\partial w_2} = 1$ なので、 1×1 と 1×1 をそれぞれの下流に流します。まず、これで $\frac{\partial y}{\partial w_2} = 1$ が求まります。次に t から s への計算を行います。上流から1の値が流れてきているので、 $1 \times \frac{\partial t}{\partial s}$ を計算します。 $\frac{\partial t}{\partial s}$ は s^2 の導関数 $2s$ となるので、順伝播で計算した具体的な s を代入して $\frac{\partial t}{\partial s} = 2s = 12$ の値を得ます。上流から流れてきた1と掛け合わせて $1 \times \frac{\partial t}{\partial s} = 12$ を下流に流していきます。最後に s から w_1 に至る計算を行います。 $\frac{\partial s}{\partial w_1} = x = 2$ なので、上流から流れてきた12と $\frac{\partial s}{\partial w_1} (= x = 2)$ を掛けて、24が $\frac{\partial y}{\partial w_1}$ の値となります。


誤差逆伝播法による勾配の求め方のまとめ

1. 計算グラフを作成

2. 順伝播の計算

3. 逆伝播の計算

- 出力から入力へ、上流から伝播してきた勾配に局所的な微分を乗算して下流のノードに伝播
- 合流地点では各パスから伝播してきた勾配を足し合わせる



27

誤差逆伝播法のまとめです。誤差逆伝播法ではまず、計算グラフを作成し、次に順伝播の計算を行い、最後に逆伝播の計算を行うことで順方向の全ての計算と、損失関数に対する全てのパラメータの微分値が求まります。つまり、勾配が求まります。

逆伝播では、出力から入力に向かって計算を行います。上流から伝播してきた勾配に局所的な微分を乗算して下流に伝播していきます。逆伝播の計算の際に合流することがあれば、合流地点では各パスから伝播してきた勾配を足し合わせます。

順伝播の計算を行うことによって、全ての変数の値がまず求まるということ、それから、逆伝播の際にそれぞれの関数の導関数に具体的な変数の値をいれて計算することで、具体的な局所的微分値が求まる、ということに注意してください。

誤差逆伝播法によるNN学習の全体像

損失の値を最小にするパラメータを探す

1. 勾配の算出: 損失に基づき、各パラメータの勾配を求める
(誤差逆伝播法により算出)
2. パラメータの更新: パラメータを勾配方向とは逆方向に微小量更新する
3. 繰り返す: ステップ1に戻る



28


NNの学習は基本的に勾配法を用いて行います。つまり、損失の勾配を計算して、勾配の逆方向に向かってパラメータを更新することで損失を最小化するパラメータを求めます。

手続き的には、1. 勾配の算出を行い、2. パラメータの更新を行い、3. 1.に戻って繰り返す、ということを行います。1の勾配の算出には誤差逆伝播法を用います。2のパラメータ更新では求めた勾配と逆方向に微小量更新することを行います。

【参考】NN中間層の逆伝播

- 全結合層(Fully Connected Layer; FC)(Affine層ともいう)
+ 活性化関数の逆伝播

隠れ層の計算グラフ



29


ここからは参考です。

NN中間層の逆伝播の計算方法について紹介します。一般的なNNの中間層は、全結合層(Fully Connected Layer; FC)もしくはAffine層と呼ばれる層の計算とその結果に対する活性化関数によって構成されます。データはデータ行列としてまとめて渡される(ミニバッチ内の全てのデータに対してまとめて線形計算を行う)ので、まず、 $A = X \cdot W + B$ を計算します。次に、 A のそれぞれの次元の値に対して、活性化関数を適用して、 Y を得ます。


パーセプトロンで習った線形式は行列計算で完結に表現されます。 W を K 次元 $\times L$ 次元の行列とすると、データ行列に対して、 $X \cdot W$ を計算することで K 次元から L 次元への線形変換を計算することができます。さらにバイアス項として重みベクトル B を足し合わせます。

【参考】活性化関数の逆伝播：ReLU関数

$$y = \begin{cases} x & (x > 0) \\ 0 & (x \leq 0) \end{cases}, \quad \frac{\partial y}{\partial x} = \begin{cases} 1 & (x > 0) \\ 0 & (x \leq 0) \end{cases}$$



順伝播時の入力 x が0より大きい場合、
上流の値をそのまま下流に流す
0以下の場合、何も流さない




30

FC層の逆伝播の計算の前にまず活性化関数の逆伝播の計算について説明します。

ReLUは $y = \begin{cases} x & (x > 0) \\ 0 & (x \leq 0) \end{cases}$ となる活性化関数ですが、この導関数は $\frac{\partial y}{\partial x} = \begin{cases} 1 & (x > 0) \\ 0 & (x \leq 0) \end{cases}$ となりますので、入力が0より大きいときと0以下のときで場合分けして計算すれば良いことになります。このReLUは順伝播時の入力 x が0より大きい場合は上流の値をそのまま下流に流して、0以下の場合、何も流さない、ということになります。

【参考】活性化関数の逆伝播：シグモイド関数

$$y = \frac{1}{1 + \exp(-x)} \quad , \quad \frac{\partial y}{\partial x} = y(1 - y)$$



※順伝播の出力 y を用いて逆伝播の出力値を算出

31

次にシグモイド関数の逆伝播について説明します。シグモイド関数を $y = \frac{1}{1 + \exp(-x)}$ としたとき、この導関数は $\frac{\partial y}{\partial x} = y(1 - y)$ となります。従って、上流から $\frac{\partial L}{\partial y}$ の値が流れてきたら、 $\frac{\partial L}{\partial y} y(1 - y)$ の値を下流に流せば良いことになります。入力の x ではなく、出力の y を使って簡単に計算できることに注意してください。

【参考】シグモイド関数の微分

$$y = \frac{1}{1 + e^{-x}} \text{ の微分}$$

$$u = 1 + e^{-x} \text{ とおくと}$$

$$y = \frac{1}{u}$$

$$\frac{dy}{du} = -\frac{1}{u^2}$$

$$\frac{du}{dx} = -e^{-x}$$

$$\frac{dy}{dx} = \frac{dy}{du} \frac{du}{dx}$$

$$= \frac{e^{-x}}{u^2} = \frac{e^{-x}}{(1 + e^{-x})^2}$$


$$= \left(\frac{1 + e^{-x}}{1 + e^{-x}} - \frac{1}{1 + e^{-x}} \right) \frac{1}{1 + e^{-x}}$$

$$= (1 - y)y$$



参考のため、シグモイド関数の微分の導出をのせておきます。


【参考】全結合(FC)層の逆伝播 (1/2)



33

次にFC層の逆伝播の計算ですが、まず、簡単な1変数の場合をみてみます。この場合FC層は $a = wx + b$ を計算するので、これらを x と w で微分した値を下流にながしていくことになります。つまり、 x には w をかけた値を渡して、 w には x を掛けた値を渡して、 b には上流の値がそのまま流れることになります。

【参考】全結合(FC)層の逆伝播 (2/2)



34


こちらは一般的な場合のFC層の逆伝播の計算になります。行列の微分が入っているため難しいのですが、公式を用いて計算するか、要素ごとに分解して計算すると、このスライドの式のようになることがわかります。

【参考】出力層の逆伝播： ソフトマックス層 + 交差エントロピー誤差

分類問題
で使用

$$y_i = \frac{\exp(o_i)}{\sum_k \exp(o_i)}$$

$$-\sum_k t_k \log_e y_k$$



損失関数の逆伝播について説明します。分類問題の場合は、ソフトマックス層と交差エントロピー誤差を組み合わせることが多いのですが、この2つを組み合わせただけの場合、出力 L に対する微分は $y_i - t_i$ という非常に簡単な式になります。 y_i がニューラルネットワークによる i クラス目の出力で、 t_i が i クラス目の正解になります。

【参考】ソフトマックス層 + 交差エントロピー誤差 の逆伝播の導出

$y_i = \frac{\exp(o_i)}{\sum_k \exp(o_k)}$, $L = -\sum_k t_k \log_e y_k$ において $\frac{\partial L}{\partial o_i}$ を求める

$$\begin{aligned} \frac{\partial L}{\partial o_i} &= \sum_c \frac{\partial L}{\partial y_c} \cdot \frac{\partial y_c}{\partial o_i} \\ &= \frac{\partial L}{\partial y_i} \cdot \frac{\partial y_i}{\partial o_i} + \sum_{c \neq i} \frac{\partial L}{\partial y_c} \cdot \frac{\partial y_c}{\partial o_i} \end{aligned}$$

着目クラス それ以外

$$\begin{aligned} &= -\frac{t_i}{y_i} \cdot y_i(1 - y_i) - \sum_{c \neq i} \frac{t_c}{y_c} \cdot (-y_i y_c) \\ &= y_i \cdot t_i - t_i + \sum_{c \neq i} t_c \cdot y_i \\ &= \sum_c t_c \cdot y_i - t_i = \mathbf{y_i - t_i} \end{aligned}$$

$$\frac{\partial L}{\partial y_c} = -\frac{t_c}{y_c} \quad (c = 1 \dots k) \quad \left(\left(\frac{f}{g} \right)' = \frac{f'g - fg'}{g^2} \right)$$

$$\begin{aligned} \frac{\partial y_i}{\partial o_i} &= \frac{\exp(o_i) \sum_k \exp(o_k) - \exp(o_i) \exp(o_i)}{(\sum_k \exp(o_k))^2} \\ &= y_i - y_i^2 = y_i(1 - y_i) \end{aligned}$$

$$\frac{\partial y_c}{\partial o_i} = \frac{-\exp(o_c) \exp(o_i)}{(\sum_k \exp(o_k))^2} = -y_i y_c \quad (c \neq i)$$

36


参考のため、ソフトマックス層と交差エントロピー誤差を組み合わせた際の計算をのせておきます。興味のある人は自分でも是非解いてみてください。

【参考】出力層の逆伝播：恒等関数 + 2乗和誤差

回帰問題
で使用

入力を
そのまま流す

$$\frac{1}{2} \sum_k (y_k - t_k)^2$$



回帰問題の場合は恒等関数と2乗和誤差を組み合わせる損失関数としますが、この微分も $y_i - t_i$ という非常に簡単な式になります。ただし、 y_i は i クラス目の出力ではなく、ニューラルネットワークの i 次元目の出力となります。 t_i も i クラス目ではなく、 i 次元目の正解となります。

まとめ

- **NNの推論**

- NNは入力層、中間層、出力層の多層構造
- 信号は入力層、中間層、出力層へと階層的に伝わる
- 中間層、出力層には活性化関数を用いる

- **NNの学習**

- 損失の値が最小になるパラメータを探す
- パラメータを勾配に基づき更新する作業を繰り返すことで探す（勾配降下法）
- 誤差逆伝播法により勾配を求める

- **計算グラフにより計算過程を視覚的に把握できる**

- ノードは局所的な計算で構成
- 順伝播：通常の計算、逆伝播：各ノードの微分（出力からのパスの積）を求められる



38

NNのまとめです。